

Fonctions discriminantes linéaires

Christine Sénac (slides manuscrits de R.André-Obrecht)
M1 Informatique

1

Fonctions discriminantes
linéaires et non linéaires

$\mathcal{Y} = \{y_1, \dots, y_n\} \quad y_n \in \mathbb{R}^d$

$K = \{k_1, \dots, k_{|K|}\} \quad \text{classes}$

$g_i: \mathcal{Y} \rightarrow \mathbb{R}^*$

$y \in k_i \iff g_i(y) \geq g_j(y) \quad i \neq j$

Problème à 2 classes

$g: \mathcal{Y} \rightarrow \mathbb{R}^*$

$y \in k_1 \iff g(y) > 0$





$y \in k_2 \iff g(y) < 0$

Observations

1 fonction discriminante
 g_i par classe

Posé par définition

Classification Binaire

- Données : quelques éléments (textes) qui appartiennent à deux classes différentes
 - classe 1 (+1 ) et classe 2 (-1 )
 - classe positive (+1 ) et classe négative (-1 )
- Tâche : entraîner un classifieur sur ces données (dites d'apprentissage) puis prédire la classe d'un nouvel élément (nouveau texte)
- Géométriquement : trouver une séparation entre les deux classes

3

Séparation Linéaire / Non Linéaire


Données séparables linéairement

Si tous les points associés aux données peuvent être séparés correctement par une frontière linéaire (**hyperplan**)

4

Données séparables linéairement

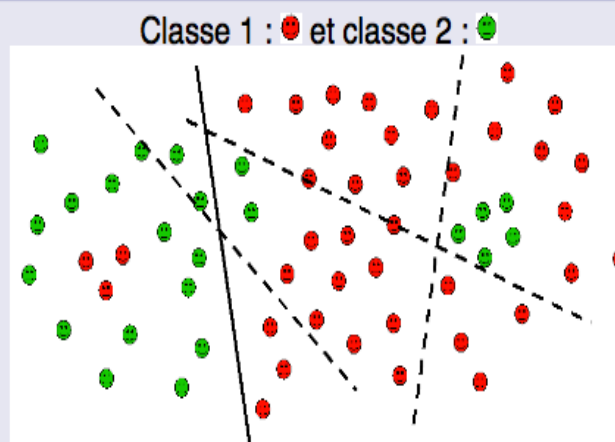
Exemple : séparation linéaire



5

Données non séparables linéairement


Exemple : pas de séparation linéaire



6

Données non séparables linéairement

Exemple : séparation non linéaire



7

Cas de 2 classes

Fonctions discriminantes linéaires


$$g(y) = w^t \bar{y}$$

avec $w = \begin{pmatrix} w_1 \\ \vdots \\ w_{d+1} \end{pmatrix}$ et $\bar{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_d \\ 1 \end{pmatrix}$

Frontière de décision :

$$\{ y \in \mathbb{R}^d \mid g(y) = 0 \}$$

hyperplan de \mathbb{R}^d
orthogonal à $\tilde{w} = \begin{pmatrix} w_1 \\ \vdots \\ w_d \\ w_{d+1} \end{pmatrix}$



Exemple dans \mathbb{R}^2

Equation de l'hyperplan


Rappel :

$$y = y_p + r \frac{\tilde{w}}{\|\tilde{w}\|}$$

$$\text{alors } r = \frac{g(y)}{\|\tilde{w}\|}$$

(distance algébrique à l'hyperplan)

$$\begin{aligned} \text{dms} \quad g(y) - g(y_p) &= \tilde{w}^t (y - y_p) \\ &= \tilde{w}^t \cdot r \frac{\tilde{w}}{\|\tilde{w}\|} \end{aligned}$$




Exemple dans \mathbb{R}^2

I Résolution du problème à 2 classes

→ neurone formel (1960-1980)

→ SVM (depuis 1990)



Recherche de l'hyperplan optimal
Existe-t-il?

Unicité?

⇒ On cherche le vecteur

w orthogonal à l'hyperplan:

Par ap. séquentiel et sur les erreurs

Hypothèses = Ensemble d'échantillons
 \bar{y} appartenant à k_1 et k_2
Apprent. supervisé

$$w? \quad \left| \begin{array}{ll} w^t \bar{y} > 0 & \text{si } y \in k_1 \\ w^t \bar{y} < 0 & \text{si } y \in k_2 \end{array} \right.$$

$$\text{On pose } \begin{array}{ll} \delta_y = 1 & \text{si } y \in k_1 \\ \delta_y = -1 & \text{si } y \in k_2 \end{array}$$

$$w? \quad \left| \begin{array}{ll} \delta_y w^t \bar{y} > 0 & \\ \delta_y \bar{y} = \text{donnée normalisée} & \end{array} \right.$$

Cas: y est bien classé

Sortie désirée
(connaissance ⇒
d'où ap. supervisé)

I.1 Algorithme du Perceptron

Fonction coût
(liée aux erreurs)
à minimiser

$$J(w) = \sum_{y \in \mathcal{Y}_{\text{mal classés}}} (-\delta_y w^t \bar{y})$$

$$\text{Si } y \text{ mal classé et } y \in K_1 \Rightarrow w^t y < 0 \Rightarrow \delta_y > 0 \Rightarrow -\delta_y w^t y > 0$$

$$\text{Si } y \text{ mal classé et } y \in K_2 \Rightarrow w^t y > 0 \Rightarrow \delta_y < 0 \Rightarrow -\delta_y w^t y > 0$$

$$\begin{cases} J(w) > 0 & \text{si erreur} \\ J(w) = 0 & \text{sans erreur} \end{cases}$$

Minimiser $J(w)$

Algorithme de Descente du gradient

$$\nabla J(w) = \sum_{y \in \mathcal{Y}_{\text{mal classés}}} -\delta_y \bar{y}$$

$$w_{n+1} = w_n - \lambda_n \nabla J(w_n)$$

BATCH

L'hyperplan est mis à jour
après traitement de
TOUTES les données

Règle du Perceptron (batch)

$$w_{n+1} = w_n + \lambda_n \sum_{y \text{ mal classés } (w_n)} \delta_y \bar{y}$$

Convergence habituelle

$$\begin{cases} \sum \lambda_n = +\infty \\ \sum \lambda_n^2 < +\infty \end{cases} \quad \text{exple: } \lambda_n = \frac{c}{n}$$

Théorème : Si les classes sont linéairement séparables, la règle de mise à jour converge en un nombre fini d'itérations ($\lambda_n = c$) ($\forall w_0$)

Minimum global
ssi séparation
linéaire

Algorithme de Rosenblatt (1958)

(on line)

1 itération sur les observations

$$\mathcal{Y} = \{y_1, y_2, \dots, y_n, y_{n+1}\}$$

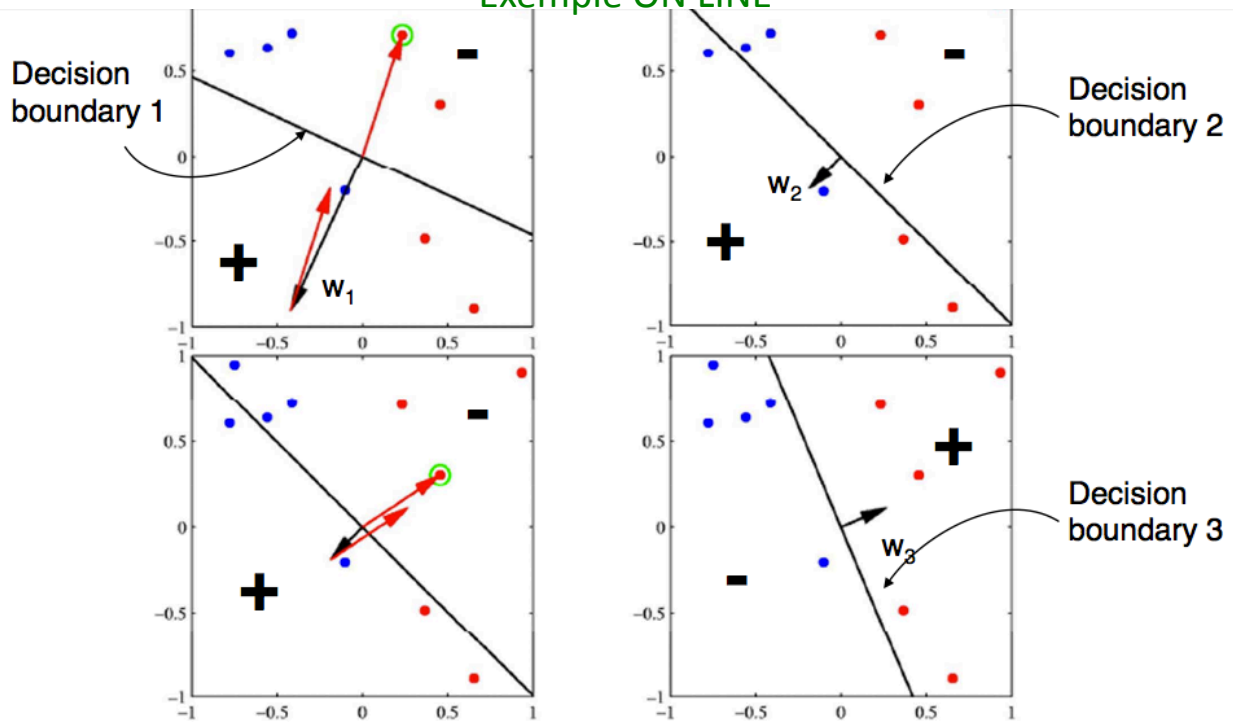
$$\begin{cases} \text{Si } y_n \text{ mal classé} \\ w_{n+1} = w_n + \lambda_n \delta_{y_n} \bar{y}_n \\ \text{Sinon} \\ w_{n+1} = w_n \end{cases}$$

(déplacement progressif de H).

ON LINE

L'hyperplan est mis à jour
après traitement de
CHAQUE donnée

Exemple ON LINE



Red points belong to the positive class,
blue points belong to the negative class

13

Batch Perceptron Algorithm

Given : training examples $(\mathbf{x}_i, y_i), i = 1, \dots, N$

Let $\mathbf{w} \leftarrow (0, 0, 0, \dots, 0)$

do

$\mathbf{delta} \leftarrow (0, 0, 0, \dots, 0)$

for $i = 1$ to N do

$u_i \leftarrow \mathbf{w} \cdot \mathbf{x}_i$

if $y_i \cdot u_i \leq 0$

$\mathbf{delta} \leftarrow \mathbf{delta} - y_i \cdot \mathbf{x}_i$

$\mathbf{delta} \leftarrow \mathbf{delta} / N$

$\mathbf{w} \leftarrow \mathbf{w} - \eta \mathbf{delta}$

until $|\mathbf{delta}| < \epsilon$

!!! Le pas η doit décroître à chaque
itération de l'apprentissage

Simplest case: $\eta = 1$ and don't normalize – 'Fixed increment perceptron'

Algorithme du Perceptron

Perceptron : Analyse

- Progressif : s'adapte toujours aux nouvelles données
- Avantages
 - Simple et efficace
 - Garantie d'apprendre un problème linéairement séparable (convergence, optimum global)
- Limitations
 - Seulement séparations linéaires
 - Converge seulement pour données séparables
 - Pas très efficace dès qu'il y a trop de descripteurs

15


I2 - Résolution avec marge

(procédures de relaxation)

$$J_R(w) = \frac{1}{2} \sum_{y \text{ mal classé}} (\delta_y w^T \bar{y} - b)^2$$

($b > 0$)

$$y \text{ mal classé} \Leftrightarrow \delta_y w^T \bar{y} < b$$



Plus la marge est grande
plus la classification est
fiable

Algorithme du
gradient

$$\nabla J = \sum_{y \text{ mal classé}} \delta_y (\delta_y w^T \bar{y} - b) \bar{y}$$

II Cas de plusieurs classes


m classes

1^{er} cas

1 contre (m-1)

→ m hyperplans $g_i, i=1 \dots m$

$$y \in k_i \Leftrightarrow \begin{cases} g_i(y) > 0 \\ g_j(y) < 0 \quad \forall j \neq i \end{cases}$$



/// = indecision

2^e cas


1 contre 1

2 par 2

$\left. \begin{array}{l} 1 \text{ contre } 1 \\ 2 \text{ par } 2 \end{array} \right\} d_{ij}, i=1 \dots m, j=1 \dots m$

$$y \in C_i \Leftrightarrow d_{ij}(y) > 0.$$

$$(\Rightarrow d_{ij} = -d_{ji}).$$



/// = indecision

3^e cas

m fonctions g_i


$$y \in C_i \iff g_i(y) > g_j(y)$$

- Pas de méthode de vote du "2 clans"
- Cas laïcisien
- Pas de régions d'indécision.

III. Réseaux de neurones multicouches

III.1. Le Neurone formel

Cellule élémentaire
(réseau à 2 couches)



z : 1 sortie booléenne


y^i : d entrées booléennes

w^d : d poids



f : fonction d'activation.
Sert à introduire une non linéarité dans le fonctionnement du neurone

$$z = f\left(\sum_{i=1}^d w_i y^i\right)$$

$$z = f(\hat{w}^T \cdot y)$$



\bar{a} seuil



\bar{a} seuil décalé

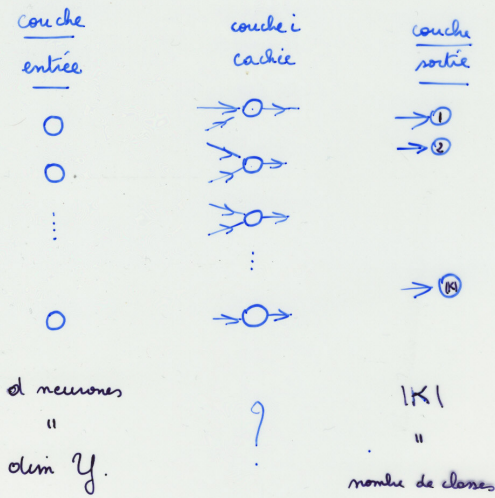
$$f(x) = \begin{cases} 1 & \text{si } x \geq a \\ 0 & \text{sinon} \end{cases}$$

$$w_{d+1} = -a$$

$$f(z) = 1 \iff w^T \bar{y} > 0$$

III 2 le réseau multicouche

= réseau de neurones formels
organisés en "couches"




Topologie à définir

en sortie



$$\textcircled{k} \rightarrow \begin{cases} 1 & \text{si } y \in \text{classe } k \\ 0 & \text{sinon} \end{cases}$$

III 3 Exemple : vers le non linéaire




$$w_1 y_1 + w_2 y_2 + w_3 \geq 0$$



\approx



$$\begin{aligned} y_2 &< 3 & -y_2 + 3 &> 0 \\ y_2 &> 1 & y_2 - 1 &> 0 \\ y_1 &< 4 & -y_1 + 4 &> 0 \\ y_1 &> 2 & y_1 - 2 &> 0 \end{aligned} \Leftrightarrow$$



1 cellule élémentaire/
hyperplan



Triangle OU carré